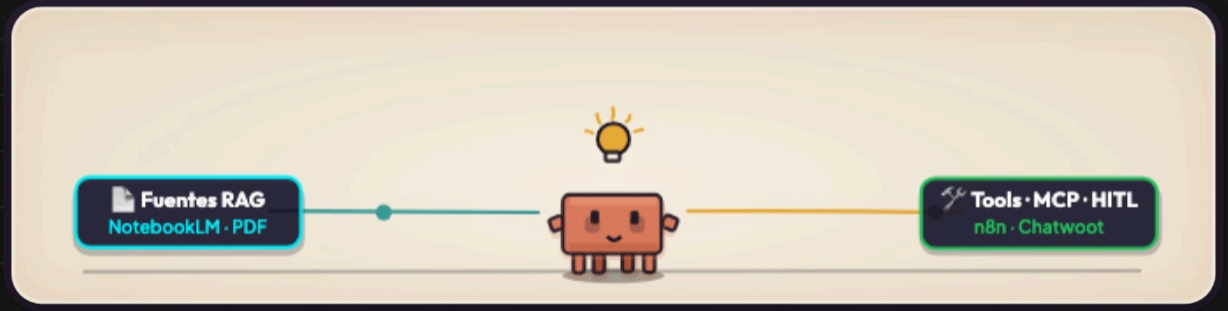
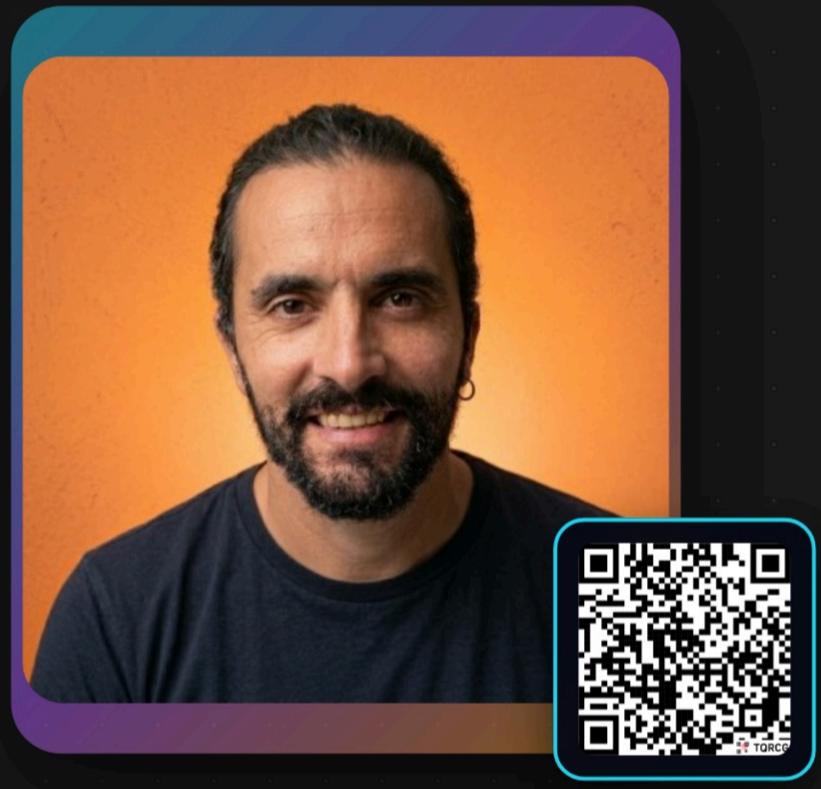
PROGRAMA DE AGENTES DE IA · CLASE 3

Arquitectura Inteligente: RAG, Herramientas y Automatización



Conocimiento (RAG) | Skills (Instrucciones) | Herramientas (Tools) | Conexiones (MCP) | Control Humano (HITL)

60 min + 30 min Q&A | Demos en vivo | NotebookLM · n8n · Chatwoot · Claude Code



TU PERSONAL TRAINER DE AI

Axel Laban Arzubi

Emprendedor: Co-fundé HolaVeggie, un token de blockchain y TheFreshAgency.

Experiencia: Lideré BI & eCommerce de Grupo Marquez y el área comercial de Avenida.com.

Laboratorio IA: Creo productos digitales hechos con IA en a13i-lab.vercel.app ↗

YouTube: Tutoriales y sistemas de IA paso a paso en @soyaxellaban ↗

Escaneá el QR para conectar en LinkedIn

ESTRUCTURA DE LA SESIÓN

Hoja de Ruta — 60 min + 30 min Q&A

De los fundamentos de RAG y arquitectura hasta flujos reales corriendo en vivo.

BLOQUE 1 · 15 MIN — 01

¿Qué necesita saber?

Instrucciones, documentos (RAG), acciones, el rol de **n8n** y qué modelo elegir.

Base de arquitectura

BLOQUE 2 · 20 MIN — 02

RAG + HITL en vivo

NotebookLM, **Google File Search + Sheets** en n8n y derivación humana en **Chatwoot**.

2 Demos en vivo

BLOQUE 3 · 15 MIN — 03

Skills, Tools y MCP

Qué función cumple cada uno, conexión **MCP en vivo en n8n** y catálogos públicos.

Enchufe universal

BLOQUE 4 · 10 MIN — 04

Elegir y comprobar

Pasos fijos vs. agente, las 3 pruebas antes de salir a producción y plantillas.

Criterio + Recursos

+ 30 minutos al final de preguntas, respuestas y revisión de casos reales.

VISIÓN ESTRATÉGICA

Pirámide de Foco Estratégico

Diferenciar dónde aportás valor irreemplazable vs. dónde la IA ya está tomando el control.



Cima: Decisión y Criterio 100% Humano

Decisiones con info incompleta, contexto humano, confianza y criterio forjado en la experiencia.

Medio: Síntesis y Análisis IA llegando ahora

Síntesis documental (RAG), redacción técnica, análisis comparativos y coordinación operativa.

Base: Procesamiento y Reporte Ya automatizado

Responder preguntas frecuentes, cargar datos, filtrar consultas y armar reportes estándar.

ACCIÓN DIRECTA

Un ejercicio simple para Potenciar tu valor

Dividí tus tareas de la semana en estas dos columnas. El resultado te va a sorprender.

Columna Izquierda · Trabajo escriptado

Delegar a IA

- Procesos paso a paso y respuestas estándar a clientes
- Reportes operativos, carga de datos y seguimiento
- Tareas repetitivas que podés explicar en un documento

↓ **La IA comprime esto:** de 3 horas → 40 minutos

Columna Derecha · Trabajo estratégico

Tu diferencial

- Criterio de negocio forjado en la experiencia real
- Relaciones comerciales, empatía y confianza humana
- Decisiones críticas e intervención en casos complejos (HITL)

↑ **Invertí acá tu tiempo liberado:** Humano + IA = imbatible

Descubrimiento común: entre el **50% y 70%** del tiempo profesional se va en la columna izquierda. Ahí está tu primera gran victoria con RAG y automatización.

LA REGLA DEL -20% DE PRODUCTIVIDAD

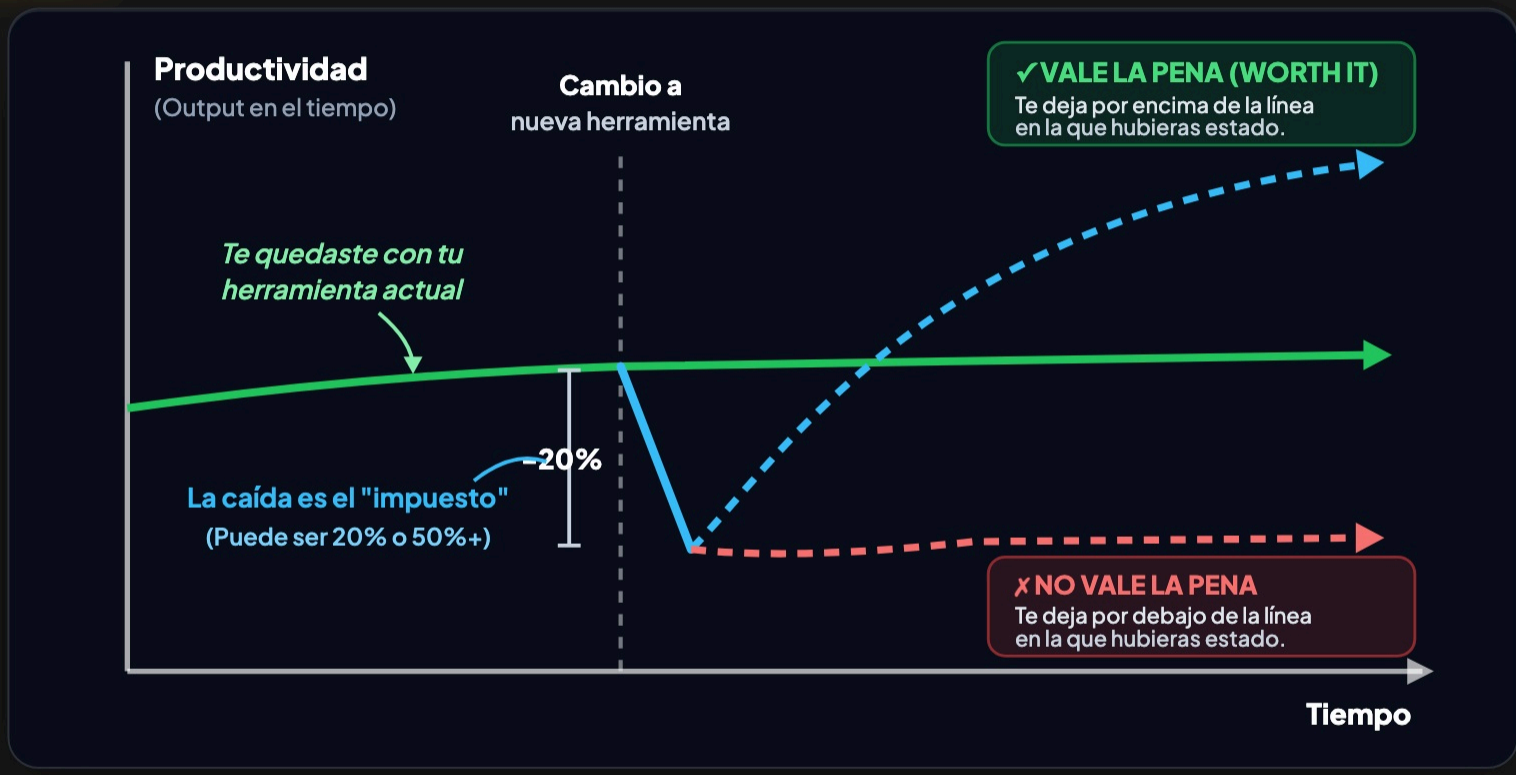
Cada cambio de herramienta es una apuesta.

Cada cambio implica una caída de productividad mientras aprendés la nueva herramienta. No es un "quizás": es una garantía.
Puede ser 20% o 50%, según el tamaño del cambio.

La pregunta honesta a hacerte:
"¿Me va a dejar POR ENCIMA de la línea en la que estaría si nunca hubiera cambiado?"

Si no podés decir que sí con seguridad, el cambio es una mala apuesta, aunque la nueva sea técnicamente mejor.

"Mejor" rara vez le gana a "consistente".



Por eso **no le digo a la gente que abandone** n8n en el segundo en que escuchan hablar de Claude Code.

Si **n8n** te funciona y estás sacando soluciones a producción, **cambiar por moda es pagar un impuesto del 20% sin ninguna razón.**

MARCO CONCEPTUAL

Tres conceptos que se confunden

En este programa construimos las tres capas. Saber dónde está parado cada una evita sobre-ingeniería.

Criterio	Automatización	Automatización con IA	Agente IA
Definición	Ejecuta tareas predefinidas con reglas fijas	Llama a un LLM vía API en uno o más pasos	Resuelve objetivos no-determinísticos con autonomía
Base lógica	`if / then` (booleana)	Pasos fijos + razonamiento LLM	Razonamiento + bucle de herramientas
Fortaleza	Rápido, confiable y 100% predecible	Procesa lenguaje natural sin perder control	Se adapta a imprevistos y decide qué usar
Debilidad	Rígido: si cambia el input, se rompe	Sin RAG puede alucinar respuestas	Menos predecible, mayor latencia y costo
Ejemplo real	Avisar en Slack cada vez que entra un lead	Clasificar el lead o responder con un PDF en n8n	Investigar cuenta, cruzar sistemas con MCP y actuar

En esta clase combinamos **flujos estructurados con IA** y **decisiones agénticas** — sumando RAG, herramientas, MCP e intervención humana (HITL).

EL MAPA DE ESTA CLASE

Dos Arquitecturas: Estructurada vs. Agéntica

Por qué usamos RAG en **n8n** para chatbots en WhatsApp/Telegram vs. flujos estocásticos en **Claude Code**.

1. Chatbot Estructurado (Determinista)

n8n · WhatsApp · Telegram

Mensaje → RAG (File Search) → Sheet → HITL

- **Comportamiento determinista:** vos definís los carriles en **n8n**; el bot sigue reglas claras y no inventa pasos libres.
- **Por qué lleva RAG:** el RAG ancla cada respuesta a tus PDFs y planillas oficiales para que no alucine frente al cliente.
- **Dónde brilla:** atención y ventas 24/7 en **WhatsApp y Telegram** con supervisión humana en **Chatwoot**.

>_ 2. Flujo Agéntico (Probabilístico / Estocástico)

Claude Code · Agentes IA

Objetivo → Piensa ↔ Skill ↔ MCP / Tool → Resultado

- **Comportamiento estocástico:** no hay un camino único; el agente decide en bucle qué explorar, qué comando correr y cómo corregir errores.
- **Por qué usa Skills + MCP:** lee **Skills** (manuales de oficio) y usa **MCP** para operar múltiples sistemas con autonomía.
- **Dónde brilla:** construir software, analizar bases complejas o automatizar trabajo interno desde **Claude Code**.

Síntesis de la clase: En canales de clientes (**WhatsApp / Telegram**) priorizá **estructura + RAG + HITL en n8n**. En tareas abiertas de creación o análisis priorizá **agentes con Skills y MCP**.

CONCEPTO CLAVE

¿Qué es RAG?

Retrieval-Augmented Generation: hacer que el asistente **busque en tus documentos reales antes de responder**.

1. Busca (Retrieval)
Consulta tus PDFs, Docs o FAQs

→

2. Selecciona (Augment)
Extrae solo los párrafos relevantes

→

3. Responde (Generation)
Redacta con datos reales + cita

Frena alucinaciones
No improvisa políticas, stock ni precios

Citas verificables
Sabés exactamente de qué página salió

Actualización en segundos
Reemplazás el PDF y cambia la respuesta

BLOQUE 0 · 5 MIN

El Paradigma de la Alucinación

Ya tenés un agente con rol y personalidad. El problema aparece cuando tiene que responder algo específico de tu negocio.

88%

de los equipos que usaron IA sin RAG en producción reportaron al menos un error crítico de datos en el primer mes.

3x

más tiempo tarda un equipo en limpiar un error de alucinación en producción que en prevenirlo con RAG desde el principio.

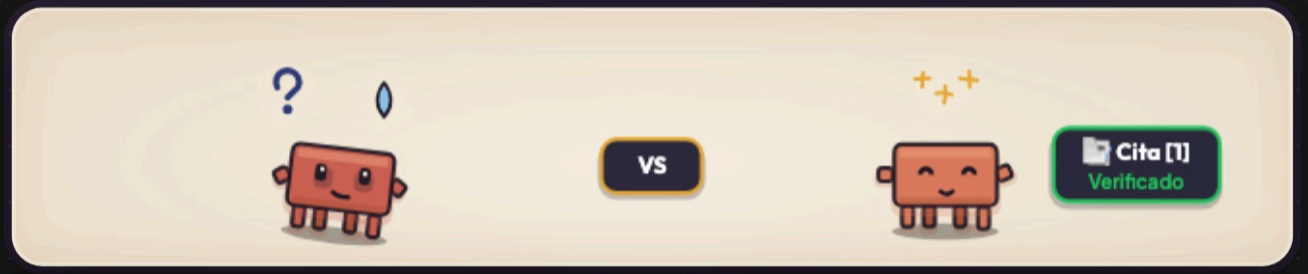
$0

cuesta agregar RAG con NotebookLM o Gemini File Search sobre un agente que ya tenés. El costo de no hacerlo es otro número.

El problema: La IA generativa sin contexto propio inventa — con el mismo tono seguro y convincente que cuando tiene razón. En un proceso real, eso no es un bug menor: es un problema de confianza que se paga caro.

Fuentes: (88%) Gartner AI in Production Survey 2024 — "AI Hallucination Incidents in Enterprise Deployments"; (3×) Databricks "Long Context RAG Performance of LLMs" — análisis de tiempo de corrección vs. prevención; ($0) Google AI Developer Blog, nov. 2025 — Google File Search API pricing.

Sin RAG vs. Con RAG



✕ Agente SIN RAG

- ✕ **Memoria genérica:** responde con datos de entrenamiento viejos
- ✕ **Alucinación:** inventa precios y políticas con total seguridad
- ✕ **Sin respaldo:** imposible verificar de dónde sacó el dato
- ✕ **Riesgo comercial:** rompe la confianza del cliente

✓ Agente CON RAG

- ✓ **Tus documentos:** lee manuales y reglamentos antes de hablar
- ✓ **Honesto:** reconoce cuando no sabe y deriva a humano
- ✓ **Trazable:** cita el documento y párrafo exacto
- ✓ **Mantenible:** actualizás el PDF y cambia la respuesta

Regla de oro: Si el dato no figura en los documentos → el asistente debe **reconocer que no sabe** y derivar a una persona (HITL).

BLOQUE 1 · 15 MIN

¿Qué necesita saber el asistente?



1. Instrucciones

Cómo debe comportarse

Rol, tono de voz, formato de respuesta y límites claros.

System Prompt · Skills

2. Documentos (RAG)

Qué información consulta

Manuales, FAQs, precios y políticas reales del negocio.

NotebookLM · File Search

3. Acciones

Qué ejecuta en otros sistemas

Leer planillas en vivo, agendar turnos o derivar a humano.

Herramientas · MCP · Chatwoot

¿Cuándo frena y pide ayuda? 1) El dato no está en las fuentes · 2) El cliente pide una persona · 3) Requiere aprobar una excepción.

RECORRIDO DE LA CONSULTA

El circuito RAG + Las 3 Fuentes

Cómo viaja cada consulta y qué tres tipos de información puede combinar el asistente en **n8n**.

1. Pregunta
Mensaje del usuario

→

2. Búsqueda
Encuentra el pasaje

→

3. Contexto
Aísla párrafos útiles

→

4. Respuesta
Cita fuente o deriva

1. Documentos fijos

Reglamentos, manuales, políticas y FAQs que cambian poco.

PDF · Docs · File Search

2. Datos en vivo

Stock del día, precios dinámicos, agenda de turnos o estado de pedido.

Google Sheets · CRM · Calendar

3. Historial de charla

Lo que ya dijo el usuario en esa sesión para mantener el hilo.

Memoria n8n · Chatwoot

LA ARQUITECTURA POR DENTRO

1. El Orquestador: ¿Por qué n8n?

El **orquestador** es la "tubería inteligente" que conecta el canal de chat con tus documentos, tus herramientas y tu equipo humano.



n8n ⭐ — 10/10 · Elegido

Nodos nativos de **Agente IA, Memoria, RAG, MCP** y control total de Chatwoot.

💰 **Gratis en servidor propio / Cloud $24/mes**

Make.com — 7/10 · Lineal

Muy visual para automatizaciones fijas, pero menos flexible para agentes con memoria y MCP.

💰 Desde $9/mes (cobra por operación)

Zapier — 4/10 · Básico

Excelente para conectar 2 apps en 5 minutos, pero muy caro y limitado cuando escala el volumen.

💰 Desde $20/mes (escala rápido en costo)

EL MOTOR DE RAZONAMIENTO

2. El Modelo IA: ¿Cuál elegir según la tarea?

El modelo es el **cerebro** que conectás dentro de n8n o Claude Code. No hace falta usar el más caro para todo.

1. Rápido y Económico

Clasificar y filtrar

Para detectar intención, etiquetar un chat o responder FAQs simples a gran escala.

- **Claude Haiku 5.5** ($0.10 / 1M)
- **GPT-5.6 Luna** ($0.20 / 1M)
- **Gemini 3.5 Flash-Lite** ($0.30 / 1M)

2. Ideal para RAG en n8n ⭐

Consultar PDFs + Sheets

El punto justo entre velocidad, ventana de **1M de tokens** (cientos de págs.) y bajo costo.

- **Gemini 3.8 Flash** ⭐ ($0.75 / 1M)

Se integra directo con **Google File Search** en nuestras demos de hoy.

3. Razonamiento Profundo

Agentes y Claude Code

Cuando el agente decide en bucle qué **Skills** y **MCP** usar o resuelve tareas complejas.

- **Claude Sonnet 5.5** ($2.00 / 1M)
- **GPT-5.6 Terra** ($2.00 / 1M)

Concepto práctico: 1M de tokens equivale a ~700.000 palabras. Con **Google File Search + Gemini Flash** no le mandás todo el libro en cada mensaje: buscás solo los párrafos útiles y gastás centavos.

DESPLIEGUE PROGRESIVO

De Copilot a Autopilot

El camino seguro para llevar un asistente a producción sin arriesgar la operación.

👨‍✈️ Paso 1: Modo Copilot (Validación)

- ✓ Probás tus documentos y citas en **NotebookLM**
- ✓ El asistente sugiere borradores; una persona supervisa
- ✓ Detectás preguntas sin respuesta y corregís tus PDFs

🤖 Paso 2: Modo Autopilot + HITL (Escala)

- ✓ Atiende consultas repetitivas 24/7 desde **n8n**
- ✓ Responde únicamente lo respaldado por tus fuentes
- ✓ Deriva a un humano en **Chatwoot** ante dudas o reclamos

BLOQUE 2 · RAG + HITL · 20 MIN

NotebookLM: validar tus fuentes antes del bot

Antes de configurar flujos en n8n, comprobá gratis en 10 minutos si tus documentos realmente tienen las respuestas.

Paso 1
Subir fuentes
PDFs, Docs, links o YouTube en un cuaderno.

Paso 2
Preguntas reales
Probar las mismas dudas que hacen tus clientes.

Paso 3
Auditar citas [1]
Tocar cada número para ver el párrafo exacto.

Paso 4
Detectar huecos
Hacer 1 pregunta que no esté y ver si frena.

Para qué alcanza con NotebookLM

- **Validar tu MVP documental:** saber si tus PDFs están claros o ambiguos.
- **Uso interno de equipo:** consultar manuales desde la web o desde la app de Gemini.

Por qué NO reemplaza probar el bot

- **No conecta con clientes:** no atiende WhatsApp ni Telegram ni usa herramientas.
- **Regla clave:** después de validar en NotebookLM, siempre hay que probar el bot en su canal real.

CRITERIO DE ARQUITECTURA

¿Dónde guardar el conocimiento?

Tres escenarios reales de negocio y qué arquitectura conviene elegir en cada uno.

Camino 1 · Sin Bot

¿Querés validar fuentes o consulta interna?

Necesitás que tu equipo consulte manuales o verificar si tus documentos sirven antes de automatizar.

👉 **Usá NotebookLM**

Ej: Onboarding RRHH, contratos legales, material de estudio.

Camino 2 · Info corta y fija

¿Es 1 producto único con reglas que casi no cambian?

Precios, garantía, preguntas frecuentes y link de pago caben en 2 carillas claras.

👉 **System Prompt en n8n + HITL**

Ej hoy: **Demo HolaVeggie** en WhatsApp + Chatwoot.

Camino 3 · Manuales + Datos vivos

¿Son PDFs extensos + stock o precios que cambian?

El bot debe buscar en reglamentos largos y además leer una planilla en tiempo real.

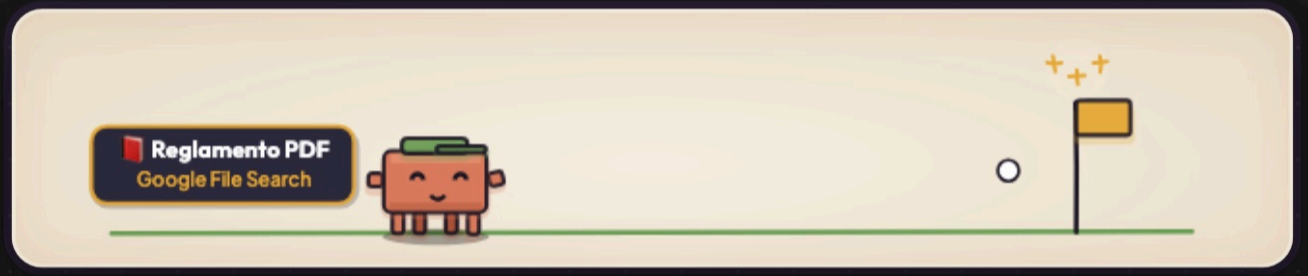
👉 **Google File Search + Sheets en n8n**

Ej hoy: **Demo Reglas del Golf** + Tienda.

La misma arquitectura sirve para cualquier rubro: soporte técnico, reclamos, turnos médicos o ventas. Solo cambian los documentos y las reglas de derivación.

DEMO 1 EN VIVO · CHAT DE N8N

Reglas del Golf: File Search + Sheets



1. Chat de n8n
o Telegram / WhatsApp

→

2. Agente Gemini 3.8
Elige qué fuente usar

→

3. Google File Search
Reglamento oficial PDF

+

4. Google Sheets
Stock y precios en vivo

Qué probamos en vivo en el Chat de n8n: vemos en pantalla cuándo consulta el **Reglamento PDF** (File Search), cuándo lee el **Stock en Sheets** y cómo reconoce cuando un dato no está en las fuentes.

DEMO 2 EN VIVO · WHATSAPP + CHATWOOT

Caso Real: HolaVeggie ("Indio")

Asistente de venta en WhatsApp con conocimiento en instrucciones + derivación humana en **Chatwoot**.

```
# ROL Y PERSONALIDAD
Sos Indio 🐾🌿, el gato asistente de HolaVeggie
("El Gran Recetario Plant-Based" · $19 USD).
Cálido, alegre y empático. Respuestas de 3-4 líneas.

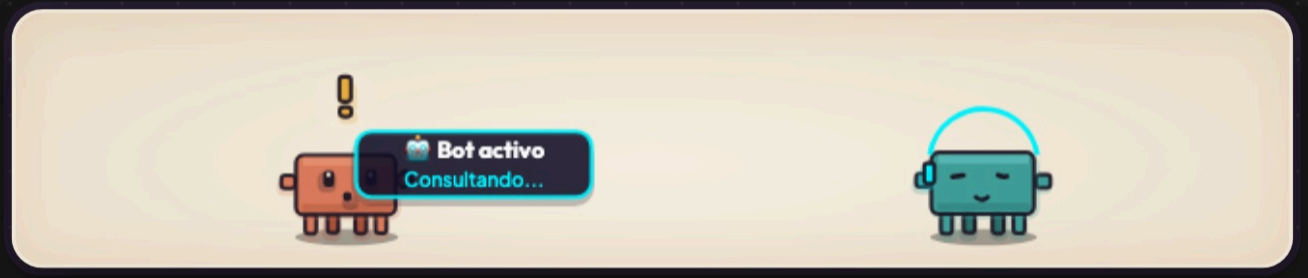
# REGLAS ESTRICTAS (GUARDRAILS)
- Prohibido inventar precios, alias o recetas.
- Si piden "MUESTRA" → enviar solo texto oficial.
- Solo entregar link del ebook al recibir:
  "PAGO HECHO" + email del comprador.
- Si pide humano o sale del carril → derivar
  a persona en Chatwoot.
```

⚡ Qué resuelve y cuándo deriva

- **Atención 24/7:** responde dudas del recetario, envía la muestra gratis y pasa datos de pago.
- **Condición de entrega:** exige `PAGO HECHO` + email antes de liberar el link de descarga.
- **Traspaso a humano:** si hay reclamo, duda de pago o pedido del cliente, deriva en **Chatwoot**.

INTERVENCIÓN HUMANA (HITL)

Derivación y Control en Chatwoot



1. Bot responde
Estado: `Pending`

→

2. Motivo HITL
Etiqueta + alerta

→

3. Humano al mando
Estado: `Open` (Bot se pausa)

→

4. Vuelve al bot
Al cerrar o devolver charla

1. Falta de información

La respuesta no está en los documentos → el bot no adivina y deriva.

2. Pedido del usuario

El cliente pide hablar con una persona o lleva 3 mensajes sin resolver.

3. Necesidad de aprobación

Descuentos, reembolsos, reclamos o excepciones sensibles.

SEGURIDAD Y COSTOS

Guardrails y Costo de Producción

🚫 Límites estrictos (Prohibido)

- ✕ Confirmar datos que no figuren en las fuentes
- ✕ Inventar descuentos, links o promesas comerciales
- ✕ Seguir respondiendo mientras el humano tiene el control

🛡️ Buenas prácticas (Obligatorio)

- ✓ Respuestas breves (3–4 líneas pensadas para celular)
- ✓ Decir "No tengo esa información" cuando falta el dato
- ✓ Entregar todo el historial previo al humano en Chatwoot

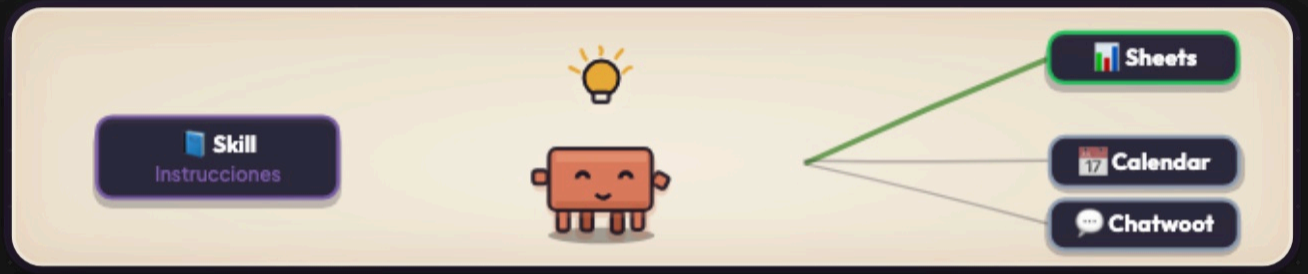
💰 **Costo orientativo para ~2.000 consultas/mes:**

NotebookLM ($0) · Google File Search (~$0–2) · Sheets ($0) · Chatwoot ($0 self-hosted) · n8n + Gemini (~$25/mes)

≈ $25 – $35 USD / MES

BLOQUE 3 · SKILLS, HERRAMIENTAS Y MCP · 15 MIN

Cómo enseñarle y conectarlo



1. Skill (Habilidad)

Guía reutilizable para una tarea

Reúne instrucciones y criterios paso a paso para hacer bien un trabajo.

Ej: Redactar respuestas claras en 4 líneas.

2. Herramienta (Tool)

Acción que el asistente ejecuta

Función puntual para leer un dato o hacer un cambio en otro sistema.

Ej: Consultar stock o crear evento en Calendar.

3. Conexión MCP

Estándar de conexión universal

El "enchufe universal" para conectar al asistente con herramientas y datos.

Ej: Conectar una hoja de cálculo o CRM vía MCP.

Diferencia clave: Skill = *cómo trabajar* (instrucciones) · **Herramienta** = *qué acción ejecuta* · **MCP** = *el estándar para conectarlo.*

DEMO EN VIVO · MCP EN N8N + CATÁLOGOS

Conexión MCP en n8n y Catálogos

Vemos en vivo las instrucciones y la conexión MCP en n8n, y dónde explorar ejemplos listos para usar.

1. Instrucciones
Define cuándo usar cada herramienta

→

2. Nodo MCP en n8n
Un solo enchufe al servidor MCP

→

3. Herramientas y Datos
Planillas, CRM, Agenda o Flujos

skills.sh ↗
Buscador de skills reutilizables para sumar a un agente.

agentskills.io ↗
Guía oficial sobre cómo estructurar una skill.

smithery.ai ↗
Catálogo de conexiones MCP con servicios y datos.

MCP Oficial ↗
Documentación introductoria del protocolo MCP.

BLOQUE 4 · ELEGIR Y COMPROBAR · 10 MIN

Elegir el flujo y hacer las 3 pruebas

Flujo de pasos fijos (Reglas + IA)

Secuencia A → B → C predefinida. La IA redacta o clasifica, pero no cambia el orden. Ideal para procesos repetitivos. **Puede incluir HITL.**

Flujo agéntico (El agente decide)

El agente elige qué fuente, herramienta o conexión MCP usar según la pregunta del usuario. **También incluye HITL.**

Prueba 1

Pregunta en Fuente A

Comprobar respuesta precisa y verificar la cita del documento.

Prueba 2

Pregunta en Fuente B / Sheet

Confirmar que selecciona la fuente correcta sin mezclar datos.

Prueba 3 · Clave

Pregunta que NO figura

Verificar que no invente, avise que no sabe y derive a humano (HITL).

REPASO INTERACTIVO

Chequeo final: ¿Verdadero o Falso?

Avanzá con la flecha (→) para revelar cada respuesta y su justificación.

Afirmación	Respuesta	Por qué
1. Un RAG reduce las alucinaciones al consultar documentos antes de responder.	Verdadero	Reduce el riesgo con fuentes reales; si no está el dato, debe avisar y derivar.
2. Probar en NotebookLM reemplaza probar el bot en WhatsApp o Telegram.	Falso	NotebookLM valida los documentos; después hay que probar el bot en el canal real.
3. Un flujo puede tener pasos fijos y usar IA para redactar una respuesta.	Verdadero	Usar IA para redactar no lo vuelve agéntico; el agente es el que decide qué herramientas usar.
4. Una Skill y una conexión MCP cumplen la misma función.	Falso	La Skill da instrucciones para una tarea; MCP conecta con herramientas y datos.
5. HITL permite que una persona revise o continúe una charla cuando hace falta.	Verdadero	En Chatwoot recibe todo el historial, toma el control y el bot se pausa.

RECURSOS LISTOS PARA IMPORTAR

Flujos y plantillas para descargar

Demo 1 · Golf RAG
File Search + Sheets en n8n (.json)

Demo 2 · HolaVeggie
WhatsApp + HITL Chatwoot (.json)

Extra · Turnos Voz
ElevenLabs + Google Calendar (.json)

Extra · Web Scraper
WhatsApp + Firecrawl en vivo (.json)

Skill descargable — RAG Architect: subila a Claude para diseñar qué fuentes y flujo usar en tu caso.

`axellaban/recursos → rag-architect.zip`

BIBLIOTECA DE REFERENCIA

Material de lectura y tutoriales

1. RAG, NotebookLM y HITL

Guía NotebookLM (ES) ↗
Consultar fuentes y verificar citas

Video NotebookLM (Google) ↗
Transformar fuentes en materiales

Google Cloud: ¿Qué es RAG? ↗
Fundamentos fácticos y actualización

Chatwoot: Human Handoff ↗
Cómo pasa el control del bot al humano

2. Skills y Conexiones MCP

Agent Skills (Oficial) ↗
Instrucciones reutilizables por tarea

MCP Oficial (Intro) ↗
Estándar de conexión con herramientas

skills.sh (Catálogo) ↗
Directorio de habilidades para agentes

Smithery (Catálogo MCP) ↗
Explorador de servidores MCP

3. Tutoriales en Video

RAG con Google File Search ↗
Configuración paso a paso en n8n

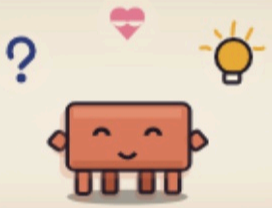
n8n: Cloud vs. Self-hosted ↗
Cómo elegir dónde alojar tus flujos

WhatsApp y Telegram en n8n ↗
Conexión de canales + Short Telegram

Instalar y usar Chatwoot ↗
Bandeja compartida para HITL

30 MINUTOS · PREGUNTAS Y RESPUESTAS

Espacio de Preguntas y Casos



1. Fuentes y RAG
NotebookLM + File Search

2. Control Humano (HITL)
Derivación en Chatwoot

3. Skills, Tools y MCP
Conexiones en n8n y agentes

¡Gracias! A construir.